

MCC002 — Probabilidad y Estadística Computacional

Trabajo Práctico Final Integrador

Dra. Rocío Milagros Zorrilla Coz

Maestría en Ciencia de la Computación, mención Computación Científica

Facultad de Ciencias - Universidad Nacional de Ingeniería

Periodo Académico 2026-1

Resumen

Este Trabajo Práctico Final integra las dieciséis semanas del curso MCC002 (Unidades 1 a 4, incluida la **Inferencia Bayesiana**). Cada grupo trabaja sobre un *dataset real, público y acotado*, formula una pregunta de investigación, ejecuta un flujo completo (EDA, IC, prueba de hipótesis, regresión y diagnóstico) y construye un **análisis bayesiano obligatorio** con prior conjugado, posterior, MAP, intervalo creíble y análisis de sensibilidad. La presentación, durante las dos últimas semanas, incluirá preguntas individualizadas sobre cualquier sección del trabajo.

Índice

1. Objetivos	2
1.1. Objetivo general	2
1.2. Objetivos específicos	2
2. Entregables	2
3. Estructura mínima del informe	2
4. Requisitos del notebook	3
5. Análisis estadísticos mínimos requeridos	3
6. Reproducibilidad y uso ético de datos	4
7. Roles del equipo	4
8. Política de uso de IA e integridad académica	4
9. Anexos por grupo — dataset y consigna específica	6
Grupo 1 — Clima espacial y geomagnetismo	7
Grupo 2 — Rendimiento académico y deserción	8
Grupo 3 — Baterías Li-ion / clínica predictiva	9
Grupo 4 — Análisis deportivo (football scouting)	10
Grupo 5 — Precipitación en el norte del Perú	11
Grupo 6 — Tráfico de red / ancho de banda	12
Grupo 7 — Indicadores socioeconómicos	13
Aviso final	14

1. Objetivos

1.1 Objetivo general

Aplicar, de forma integrada y críticamente fundamentada, las herramientas probabilísticas y estadísticas estudiadas en las dieciséis semanas del curso (incluyendo inferencia bayesiana) al análisis de un dataset real, produciendo conclusiones cuantitativas defendibles, reproducibles y comunicables.

1.2 Objetivos específicos

1. Formular una pregunta de investigación estadísticamente tratable.
2. Documentar el dataset y construir un diccionario de variables.
3. Ejecutar limpieza y preprocesamiento reproducibles.
4. Realizar EDA, descriptivos y ajustes paramétricos (MLE / MoM).
5. Construir al menos un intervalo de confianza y una prueba de hipótesis frecuentista.
6. Ajustar e interpretar un modelo de regresión múltiple con diagnóstico.
7. Realizar un **análisis bayesiano** con prior conjugado, posterior, MAP, intervalo creíble y sensibilidad al prior, y compararlo con los resultados frecuentistas.
8. Discutir limitaciones, supuestos, validez y reproducibilidad.

2. Entregables

- (a) **Informe en PDF** con la estructura de la Sección 3.
- (b) **Jupyter Notebook (.ipynb)** ejecutable de extremo a extremo (Sección 4).
- (c) **Presentación oral** de 15 + 10 minutos.
- (d) **Declaración individual de contribución** firmada (plantilla en la Sección 7).
- (e) **Declaración de uso de IA** (Sección 8).

3. Estructura mínima del informe

El informe debe contener las siguientes **15 secciones**, en orden:

1. Introducción y pregunta de investigación.
2. Descripción y citación del dataset.
3. Diccionario de variables.
4. Limpieza y preprocesamiento.
5. Análisis exploratorio (EDA).
6. Estadística descriptiva.
7. Visualizaciones (mínimo 6 figuras de calidad publicable).

8. Análisis de incertidumbre frecuentista: al menos un IC analítico y uno por bootstrap.
9. Inferencia estadística frecuentista: al menos una prueba de hipótesis con tamaño de efecto.
10. Modelo de regresión y diagnóstico: OLS múltiple, 4 plots diagnósticos canónicos, 1 test formal y validación cruzada k -fold.
11. **Análisis bayesiano**: especificación del modelo (prior + verosimilitud), posterior conjugada, MAP, intervalo creíble 95 %, análisis de sensibilidad al prior, comparación con el resultado frecuentista de §8/§9 y, cuando corresponda, sampler Metropolis-Hastings.
12. Interpretación integrada.
13. Limitaciones y validez.
14. Conclusiones.
15. Declaración individual de contribución.

4. Requisitos del notebook

- Entorno: Python 3.10+, `numpy`, `scipy`, `pandas`, `matplotlib`, `seaborn`, `statsmodels`.
- Estructura interna que replique la secuencia del curso:

Problema real → Marco teórico → Solución algorítmica → Evaluación crítica, repetida para cada bloque (descriptivo, inferencial, regresión y bayesiano).
- **Reproducibilidad**: `numpy.random.seed(...)` al inicio, `requirements.txt` y descarga del dataset documentada.
- **Bayesiano**: cálculo cerrado de la posterior conjugada implementado explícitamente. El sampler Metropolis-Hastings, cuando aplique, debe estar **implementado desde cero** (sin usar `pymc` ni `numpyro` como caja negra; estos pueden usarse solo como verificación cruzada).

5. Análisis estadísticos mínimos requeridos

- 1 ajuste paramétrico (MLE) con `scipy.stats.<dist>.fit()`.
- 1 IC analítico (z o t).
- 1 IC por bootstrap.
- 1 prueba de hipótesis con tamaño de efecto.
- 1 regresión lineal múltiple con `statsmodels`.
- 4 plots diagnósticos canónicos (residuales vs. ajustados, QQ-plot, scale-location, residuales vs. leverage).
- 1 test formal de supuestos (Breusch-Pagan o Shapiro-Wilk).
- 1 validación cruzada k -fold ($k=5$ o 10).
- **1 modelo bayesiano conjugado** con prior + posterior + MAP + intervalo creíble 95 %.
- **1 análisis de sensibilidad al prior** (al menos dos priors distintos).
- **1 sampler Metropolis-Hastings** desde cero (obligatorio cuando el modelo no admite forma cerrada; bonus si la conjugación es directa).

6. Reproducibilidad y uso ético de datos

- El notebook debe ejecutarse desde cero sin intervención manual.
- Respetar la licencia del dataset.
- No reidentificar individuos.
- Reportar limitaciones que afecten a poblaciones vulnerables.

7. Roles del equipo

Todos los miembros son co-responsables del proyecto en su totalidad. Cualquier integrante puede ser interrogado durante la presentación sobre cualquier tabla, figura, prueba, conclusión o línea de código.

Plantilla — Declaración individual de contribución

Declaración individual de contribución			
Grupo: _____ Período: 2026-1			
Miembro	Tareas asumidas	% contrib.	Firma

Declaramos que todos los miembros conocen y entienden la totalidad del proyecto, incluido el análisis bayesiano, y son capaces de explicar cualquier sección durante la sustentación oral.

8. Política de uso de IA e integridad académica

El uso de herramientas de IA generativa (ChatGPT, Claude, Copilot, Gemini, etc.) **está permitido** como apoyo (búsqueda de documentación, depuración de código, mejora de redacción), siempre y cuando el grupo mantenga el control intelectual del proyecto.

1. **Declaración obligatoria.** Anexo con herramientas, propósito específico, sección y nivel de uso.
2. **Comprensión efectiva.** Durante la sustentación, cualquier integrante puede ser preguntado por cualquier sección, **incluyendo la derivación de la posterior bayesiana y el código del sampler MH.**
3. **Inconsistencias.** Inconsistencias entre notebook, informe, resultados y exposición oral pueden penalizar hasta **4 puntos sobre 20.**
4. **Citación obligatoria.** Datasets, código y fuentes externas deben citarse.
5. **Sin envío directo de IA.** No se permiten textos, código o figuras producidos íntegramente por IA sin edición y comprensión.
6. **Licencias.** Respetar la licencia de cada dataset.
7. **Exámenes individuales.** Esta política no aplica a evaluaciones individuales en aula.

Plantilla — Declaración de uso de IA

Declaración de uso de IA			
Grupo: _____			
Herramienta	Propósito	Sección	Nivel de uso
Declaramos que entendemos plenamente todo el contenido del informe y del notebook, incluido el análisis bayesiano, y que somos capaces de explicar cualquier parte del trabajo.			
Firmas: _____			

Convención de nombres de archivo:

- Archivo principal del grupo: MCC002_2026-1_GrupoS_Apellidos.zip
- MCC002_GrupoS_Informe.pdf
- MCC002_GrupoS_Notebook.ipynb
- MCC002_GrupoS_Slides.pdf
- data/dataset_principal.csv

9. Anexos por grupo — dataset y consigna específica

A continuación se entrega la consigna específica de cada grupo: dataset principal, dataset de respaldo, pregunta de investigación central, preguntas secundarias y tareas mínimas.

Importante. Todos los grupos tienen **dificultad equivalente**: las consignas están calibradas para exigir un esfuerzo comparable. Los datasets más simples reciben tareas adicionales (transformaciones obligatorias, controles por subgrupo); los más complejos están *recortados* a una ventana o subset manejable.

Grupo 1 — Clima espacial y geomagnetismo

Miembros: Aldo Ygnacio Arriola Cordova, Niels Victor Pacheco Barrios, David Saul Quispe Calloapaza.

Dataset principal. NOAA/GFZ Kp index (recortado a 2010–2023) — <https://kp.gfz-potsdam.de/en/data>

Dataset de respaldo. SILSO Daily Sunspot Number — <https://www.sidc.be/SILSO/datafiles>

Pregunta central. ¿Existe evidencia estadística de que el índice Kp es significativamente más severo durante los máximos del ciclo solar que durante los mínimos, y cómo se distribuye Kp condicional al ciclo?

Preguntas secundarias.

1. ¿Qué distribución (Gamma, Lognormal, Weibull) ajusta mejor Kp con tormenta ($Kp \geq 5$)?
2. Proporción anual de horas con tormenta y su IC 95 %.
3. ¿Hay diferencia significativa de Kp entre verano e invierno boreales?
4. ¿Puede predecirse Kp a partir de variables solares retardadas (sunspot, F10.7)?
5. Justificar el uso de una cadena de Markov de bajo orden (motivación, no implementación).

Tareas mínimas. Plots: serie anual, histograma + Gamma, boxplot por año, scatter Kp vs. sunspot, QQ-plot. Descriptivos por año (media, mediana, IQR, asimetría, curtosis). IC 95 % Wilson y bootstrap para la proporción de tormentas. Prueba Welch o Mann-Whitney Kp máximo vs. mínimo solar y d de Cohen. Regresión OLS $Kp \sim \text{sunspot} + \text{F10.7} + \text{mes}$.

Análisis bayesiano obligatorio. Modelo Beta-Binomial para la tasa anual de tormentas:

$$p \sim \text{Beta}(\alpha, \beta), \quad X \sim \text{Bin}(n, p), \quad p \mid X \sim \text{Beta}(\alpha + x, \beta + n - x).$$

Reportar MAP, intervalo creíble 95 % y comparar con el IC frecuentista. Sensibilidad: prior de Jeffreys $\text{Beta}(1/2, 1/2)$ vs. prior informativo basado en el ciclo solar previo. **MH (bonus):** muestrear de la posterior de los parámetros de la Gamma para Kp con tormenta.

Errores a evitar. Asumir independencia entre horas; ignorar autocorrelación en los SE de la regresión.

Grupo 2 — Rendimiento académico y deserción

Miembros (4): Adderly Orlando Diaz Tapia, Jorge Luis Miranda Zarate, Susana Isabel Suarez Maciel, Luis Angel Vilca Aguilar.

Dataset principal. UCI Predict Students' Dropout and Academic Success — <https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>

Dataset de respaldo. UCI Student Performance (Math + Portuguese) — <https://archive.ics.uci.edu/dataset/320/student+performance>

Pregunta central. ¿Qué factores demográficos, socioeconómicos y académicos están asociados con el éxito o el abandono universitario?

Preguntas secundarias.

1. Proporción global de deserción y su IC 95 %.
2. ¿Hay diferencia significativa en la tasa de deserción entre becados y no becados?
3. ¿La nota de admisión está asociada con las unidades aprobadas en el 1.^{er} semestre?
4. Diferencia por género.
5. Predicción de unidades aprobadas con regresión múltiple.

Tareas mínimas. Plots: barras Target, boxplot Admission grade por Target, mosaico Gender $\times$ Target, scatter admisión vs. unidades, matriz de correlación. IC 95 % Wilson y bootstrap. Prueba χ^2 Scholarship $\times$ Target y Welch admisión Graduate vs. Dropout + d de Cohen. Regresión OLS sobre unidades aprobadas.

Análisis bayesiano obligatorio. Modelo Beta-Binomial para la tasa de deserción. Reportar posterior, MAP e intervalo creíble. Sensibilidad: Beta(1, 1) vs. Beta(α, β) informativo basado en estadísticas nacionales de deserción universitaria. **MH (bonus):** posterior del coeficiente clave de una regresión logística sobre Target binarizado.

Errores a evitar. Confundir asociación marginal con condicional; no controlar por edad.

Grupo 3 — Baterías Li-ion / clínica predictiva

Miembros: Luis Antonio Selis Vasquez, Jhon Herbers Tellez Heredia, Richard Armando Villanueva Retamozo.

Dataset principal. NASA Battery Aging — restringido a B0005 y B0006 — <https://www.kaggle.com/datasets/patrickfleith/nasa-battery-dataset>

Dataset de respaldo. UCI Breast Cancer Wisconsin (Diagnostic) — <https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>

Pregunta central. ¿Cómo se degrada la capacidad de descarga de las baterías Li-ion en función del número de ciclos y la temperatura ambiente, y qué nivel de incertidumbre tenemos sobre la predicción del fin de vida (EOL al 70 % de la capacidad inicial)?

Preguntas secundarias.

1. Distribución de la capacidad inicial.
2. ¿La temperatura afecta significativamente la pendiente de degradación?
3. IC para el ciclo de EOL.
4. ¿Es la degradación lineal en ciclos?
5. Transferibilidad entre B0005 y B0006.

Tareas mínimas. Plots: capacidad vs. ciclo, histograma de capacidades, scatter T vs. pendiente, residuales vs. ajustados. IC 95 % bootstrap para el ciclo de EOL. Prueba: comparar pendientes con t o ANCOVA simple. Regresión OLS `capacity ~ cycle + temperature + cycle:temperature`.

Análisis bayesiano obligatorio. Modelo Normal-Normal para la tasa de degradación β_1 (pendiente):

$$\beta_1 \sim \mathcal{N}(\mu_0, \tau_0^2), \quad \hat{\beta}_1 \sim \mathcal{N}(\beta_1, \sigma^2/S_{xx}),$$

con posterior conjugada cerrada. Reportar MAP, intervalo creíble 95 % y comparar con el IC del coeficiente OLS. Sensibilidad: prior plano ($\tau_0 \rightarrow \infty$) vs. prior informativo basado en otra batería.

MH (bonus): posterior conjunta $(\beta_0, \beta_1, \sigma)$.

Errores a evitar. Tratar ciclos consecutivos como independientes; promediar baterías sin justificar.

Grupo 4 — Análisis deportivo (football scouting)

Miembros: César Raúl Bernaola Gayoso, Carlo André Castro Galindo, Camilo Jorge Vinatea Chávez.

Dataset principal. FIFA 22 Complete Player Dataset — <https://www.kaggle.com/datasets/stefanoleone992/fifa-22-complete-player-dataset>

Dataset de respaldo. UCI Concrete Compressive Strength — <https://archive.ics.uci.edu/dataset/165/concrete+compressive+strength>

Pregunta central. ¿Qué atributos técnicos y físicos explican el valor de mercado $\log(\text{value_eur})$ y cuán precisa es la predicción para nuevos jugadores?

Preguntas secundarias.

1. Distribución de `value_eur` (justificar la transformación logarítmica).
2. Sueldo Premier vs. La Liga.
3. Correlación `overall` – `value_eur`.
4. Atributos técnicos vs. físicos.
5. Papel de la edad.

Tareas mínimas. Transformación logarítmica obligatoria sobre `value_eur` y `wage_eur`. Plots: histograma de $\log(\text{value_eur})$, boxplot por liga, scatter `overall` vs. $\log(\text{value_eur})$, matriz de correlación. IC bootstrap para mediana del sueldo por liga. Prueba Welch sobre $\log(\text{wage_eur})$ entre dos ligas + d de Cohen. Regresión OLS $\log(\text{value_eur}) \sim \text{overall} + \text{age} + \text{position} + \text{league}$.

Análisis bayesiano obligatorio. Modelo Beta-Binomial para la proporción de jugadores con `overall` ≥ 85 por liga. Posterior, MAP, intervalo creíble. Sensibilidad: Beta(1,1) vs. informativo. Comparar dos ligas usando posteriores empíricos. **MH (bonus):** muestrear posterior del coeficiente de `overall` en la regresión.

Errores a evitar. No transformar `value_eur`; ignorar VIF (colinealidad `overall`–`potential`).

Grupo 5 — Precipitación en el norte del Perú

Miembros: Olenka Helene Díaz Vega, Greta Solange Díaz Vega, Carlos Enrique Gallo Lugo.

Dataset principal. SENAMHI — estaciones convencionales del norte (Piura, Tumbes, Lambayeque, Cajamarca, La Libertad) — <https://www.senamhi.gob.pe/?p=estaciones>

Dataset de respaldo. Rainfall in Northwest Peru (CSV consolidado, Kaggle) — <https://www.kaggle.com/datasets/giuliogalmarini/rainfall-in-northwest-peru>

Pregunta central. ¿Cómo se distribuye estadísticamente la precipitación mensual en el norte del Perú y cuál es la diferencia entre años Niño y años neutrales?

Preguntas secundarias.

1. Distribución (Gamma/Lognormal/Exponencial) de PP mensual no nula.
2. Probabilidad empírica de mes con PP > 100 mm + IC.
3. Niño vs. neutro (1982-83, 1997-98, 2015-16, 2017, 2023 vs. neutrales).
4. Correlación altitud vs. PP media.
5. Predicción por regresión.

Tareas mínimas. Consolidación obligatoria de 3–5 estaciones en un único CSV. Plots: serie por estación, histograma + Gamma ajustada, boxplot Niño vs. neutro, scatter altitud vs. PP. IC 95 % bootstrap para PP media anual. Prueba Welch o Mann-Whitney + d de Cohen. Regresión OLS `PP_mensual ~ mes + altitud + estacion`.

Análisis bayesiano obligatorio. Modelo Gamma-Exponencial conjugado para la tasa λ del modelo exponencial sobre PP no nula:

$$\lambda \sim \text{Gamma}(\alpha, \beta), \quad x_i \sim \text{Exp}(\lambda).$$

Posterior, MAP $\hat{\lambda}$, intervalo creíble 95 %. Sensibilidad: prior plano vs. informativo basado en años neutrales. **MH (bonus):** posterior de los parámetros (shape, scale) de la Gamma directamente sobre PP no nula.

Errores a evitar. Asumir normalidad de la precipitación; agregar estaciones sin justificar.

Grupo 6 — Tráfico de red / ancho de banda

Miembros: Alex Ernesto Segura Nuñez, Royer Amed Lopez Flores, César Mallaupoma Orellana.

Dataset principal. UCI Internet Firewall Data Set — <https://archive.ics.uci.edu/dataset/542/internet+firewall+data>

Dataset de respaldo. NASA HTTP Server Logs — 1 semana de julio 1995 — <https://www.kaggle.com/datasets/souhagaa/nasa-access-log-dataset-1995>

Pregunta central. ¿Cómo se distribuye estadísticamente el tamaño de las sesiones (Bytes) y existe diferencia significativa entre sesiones permitidas (allow) y rechazadas (deny)?

Preguntas secundarias.

1. ¿Bytes sigue una distribución lognormal o Pareto?
2. Proporción de rechazos + IC.
3. Ancho de banda promedio + IC.
4. Correlación duración – Bytes.
5. Predicción de Bytes.

Tareas mínimas. Transformación logarítmica obligatoria sobre Bytes, Packets y Elapsed Time. Plots: histograma log-log de Bytes, QQ-plot lognormal, boxplot por Action, scatter en log-log. IC 95 % Wilson y bootstrap para la tasa de rechazo. Prueba Welch o Mann-Whitney sobre $\log(\text{Bytes}) + d$ de Cohen. Regresión OLS $\log(\text{Bytes}) \sim \log(\text{Packets}) + \log(\text{Elapsed Time}) + \text{Action}$.

Análisis bayesiano obligatorio. Modelo Beta-Binomial para la tasa de rechazo. Posterior, MAP, intervalo creíble. Sensibilidad: Beta(1, 1) vs. prior informativo basado en literatura ISP. Comparar con el IC de Wilson. **MH (bonus):** muestrear posterior de μ, σ^2 del modelo lognormal sobre Bytes.

Errores a evitar. Usar la media aritmética sin transformar; no documentar filtrado de ceros y outliers.

Grupo 7 — Indicadores socioeconómicos

Miembros: Joseph Cesar Alcazar Coronado, Hipólito Arturo Riveros Guevara, Mario Isaac Salguero Bohorquez.

Dataset principal. World Bank — World Development Indicators (año fijo 2019, 12–15 indicadores) — <https://databank.worldbank.org/source/world-development-indicators>

Dataset de respaldo. UCI Adult Census Income — <https://archive.ics.uci.edu/dataset/2/adult>

Pregunta central. ¿Qué relación cuantitativa existe entre la inversión en educación, el ingreso nacional y la esperanza de vida en los países del mundo, controlando por región y grupo de ingreso?

Preguntas secundarias.

1. Distribución de la esperanza de vida.
2. IC 95 % para la esperanza de vida media en América Latina.
3. Ingreso alto vs. bajo.
4. Educación vs. esperanza de vida controlando por PIB.
5. Validación cruzada por región.

Tareas mínimas. Fijar año (2019) y lista escrita de 12–15 indicadores al inicio. Plots: histograma esperanza de vida, boxplot por región, scatter log(GDP) vs. esperanza, matriz de correlación. IC 95 % t y bootstrap para media regional. Prueba Welch ingreso alto vs. bajo + d de Cohen. Regresión OLS $\text{life_expectancy} \sim \log(\text{GDP_per_capita}) + \text{education_expenditure_GDP} + \text{region}$.

Análisis bayesiano obligatorio. Modelo Normal-Normal conjugado para la media regional de esperanza de vida (con σ conocido):

$$\mu \sim \mathcal{N}(\mu_0, \tau_0^2), \quad x_i \sim \mathcal{N}(\mu, \sigma^2).$$

Posterior, MAP, intervalo creíble 95 %. Sensibilidad: prior plano vs. prior informativo basado en la media mundial. Discutir convergencia frecuentista-bayesiano cuando $\tau_0 \rightarrow \infty$. **MH (bonus):** posterior del coeficiente de educación en la regresión.

Errores a evitar. Ignorar valores faltantes; interpretar coeficientes como efectos causales.

Aviso final

Es posible ajustar los datasets recomendados durante la semana de confirmación (Semana del 24 de junio), en caso de que un grupo identifique una alternativa equivalente justificada por escrito. Este cambio de dataset no modifica el plazo de entrega final.